Optimización de trayectorias para robots móviles de rescate en entornos colapsados mediante algoritmos genéticos

Aguaya, Julia – Andriollo, Isabella – Feldkircher, Valentín

Universidad Tecnológica Nacional, Facultad Regional Rosario

Abstract

Este trabajo aborda el problema de la planificación de trayectorias para robots móviles en entornos colapsados, caracterizados por obstáculos irregulares, incertidumbre y dinamismo. Se propone la aplicación de un algoritmo genético como alternativa a los métodos clásicos de búsqueda, como A, con el objetivo de mejorar la adaptabilidad y eficiencia en escenarios de rescate. La metodología incluyó el desarrollo de un entorno de simulación 2D basado en cuadrículas, que representa un edificio colapsado con diferentes tipos de obstáculos (livianos y pesados). Para ello se generó una población inicial de trayectorias aleatorias, se evaluó su aptitud penalizando colisiones y premiando la llegada a la meta, y se aplicaron operadores genéticos (selección por ruleta, cruzamiento, mutación y elitismo). Los resultados demuestran que el algoritmo genético genera caminos viables con longitudes similares a las de A*, pero con una adaptabilidad superior en entornos complejos y dispersos. Se concluye que los algoritmos genéticos son una herramienta prometedora para la planificación de trayectorias en contextos de rescate, ofreciendo un balance óptimo entre eficiencia y robustez frente a la incertidumbre ambiental.*

Palabras Clave

Robótica móvil; Algoritmos genéticos; Planificación de trayectorias; A*; Rescate en entornos colapsados; Simulación.

Introducción

En los últimos años, la robótica de rescate ha adquirido una importancia creciente debido a la necesidad de intervenir en situaciones críticas como terremotos, explosiones o derrumbes estructurales, donde el acceso rápido y seguro a las víctimas es fundamental. En estos escenarios, los robots móviles se convierten en aliados estratégicos al poder ingresar en zonas de difícil acceso o peligrosas para los rescatistas humanos, contribuyendo a reducir riesgos y optimizar los tiempos de búsqueda.

Sin embargo, los entornos colapsados presentan características altamente dinámicas y parcialmente desconocidas, marcadas por la presencia de escombros, muros caídos, vigas entrecruzadas y obstáculos de distinta naturaleza. Estas condiciones imponen serias limitaciones a los métodos clásicos de planificación de trayectorias, como el algoritmo A*, el cual, si bien garantiza soluciones óptimas en entornos estáticos, pierde eficacia en escenarios donde la configuración del terreno cambia constantemente.

Diversos estudios han documentado la complejidad de los derrumbes. Por ejemplo, un colapso total de un edificio de 10 pisos de hormigón armado puede generar entre 3.000 y 5.000 toneladas de escombros, ocupando un área aproximada de 1.500 a 2.500 m², con alturas de acumulación promedio de 1,5 a 2 metros. Estos restos presentan una distribución heterogénea, alternando zonas de alta densidad casi intransitables con corredores de baja densidad que podrían ser aprovechados para el desplazamiento robótico. Este tipo de características hace necesario contar con algoritmos capaces de adaptarse y aprender en tiempo real.

En este contexto, los Algoritmos Genéticos (AG) se plantean como una alternativa prometedora. Inspirados en los principios de selección natural, los AG permiten explorar simultáneamente múltiples trayectorias, adaptarse a cambios inesperados en el en-

torno y optimizar criterios como seguridad, distancia y tiempo de recorrido. De este modo, el presente trabajo busca explorar la viabilidad del uso de algoritmos genéticos en la planificación de trayectorias de robots móviles en entornos colapsados, comparando sus resultados con el algoritmo A* como referencia tradicional.

Elementos del Trabajo y Metodología

Este trabajo se enmarca en la simulación y análisis de técnicas de planificación de trayectorias aplicadas a robots móviles en entornos colapsados. Para ello, se diseñó un entorno computacional en dos dimensiones (2D), con parámetros ajustables que permiten representar diferentes configuraciones de escombros y obstáculos, semejantes a los que se presentan en escenarios de derrumbe.

Entorno de simulación

El mapa de trabajo corresponde a una cuadrícula de 10×10 celdas, donde cada celda puede adoptar uno de los siguientes estados:

- **Obstáculo Liviano (1):** zona atravesable pero con penalización en la función de aptitud, simulando escombros livianos.
- **Obstáculo Pesado (2):** zona infranqueable, que representa muros o vigas colapsadas.
- **Camino (3-4):** trayectoria recorrida por el robot, diferenciando si el paso fue por celdas libres o por escombros livianos.

La posición inicial se fijó en la esquina superior izquierda de la cuadrícula, mientras que la meta se ubicó en la esquina inferior derecha. Esta disposición busca emular un ingreso a la zona afectada y un objetivo específico de rescate.

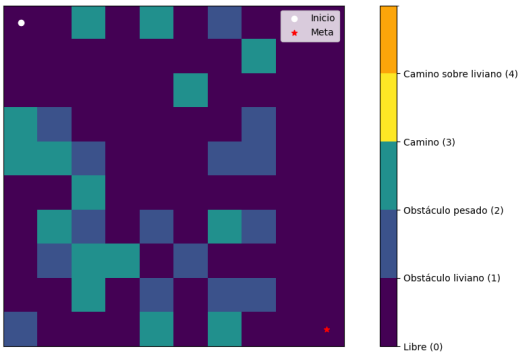


Figura 1: Ejemplo de cuadrícula 10×10 con obstáculos distribuidos aleatoriamente.

Función de Aptitud

La función de aptitud fue diseñada para guiar la búsqueda de trayectorias viables y seguras, asignando penalizaciones o recompensas en función de las características del recorrido. El valor de aptitud final se obtiene como la suma de diferentes componentes:

- **Revisitas y retrocesos:** cada vez que el robot vuelve a una celda ya visitada se penaliza con $P_{\text{revisita}} = 10$, y si se detecta un retroceso tipo A-B-A se agrega $P_{\text{backtracking}} = 15$.
- **Obstáculos livianos:** atravesar una celda con escombros livianos genera un costo de $P_{\text{liviano}} = 20$.
- **Movimientos inválidos:** cada intento de salir de los límites del mapa recibe una penalización de $P_{\text{fuera}} = 8 \times (\text{número de intentos})$.
- **Llegada a la meta:** si el individuo alcanza la meta, se otorga una recompensa de $R_{\text{meta}} = -600 + (\text{longitud del camino})$.
- **Distancia a la meta:** si no se llega al objetivo, se penaliza con $P_{\text{distancia}} = 6 \times d_{\text{Manhattan}}$.
- **Pasos redundantes:** se añade una penalización leve proporcional a la longitud del recorrido, $P_{\text{redundante}} = 0{,}2 \times (\text{número de pasos})$, que busca favorecer caminos más directos sin castigar en exceso la exploración.

En síntesis, la función de aptitud puede expresarse como:

$$F = P_{\text{revisitas}} + P_{\text{backtracking}} + P_{\text{liviano}} \quad (1)$$
$$+ P_{\text{fuera}} + P_{\text{distancia}} + R_{\text{meta}} \quad (2)$$

donde un valor más bajo de F indica un mejor desempeño. Esta versión refinada reduce la redundancia de pasos y promueve trayectorias más directas, contribuyendo a una convergencia más estable del algoritmo genético.

Algoritmo Genético (AG)

Se implementó un Algoritmo Genético (AG) canónico, técnica inspirada en los procesos evolutivos naturales y ampliamente utilizada en problemas de optimización [2].

- **Codificación:** cada individuo representa una secuencia de movimientos posibles (arriba, abajo, izquierda, derecha), con un máximo de 35 pasos, siguiendo enfoques similares a los empleados en planificación robótica [10].
- **Población inicial:** generada de forma aleatoria, con un tamaño de 200 individuos, en línea con configuraciones reportadas en la literatura [11].
- **Evaluación de aptitud:** se diseñó una función que penaliza colisiones con obstáculos, movimientos fuera del mapa, retrocesos innecesarios y pasos sobre escombros livianos. Se premia la llegada a la meta con un fuerte incentivo negativo en el puntaje, favoreciendo soluciones viables. Este esquema sigue recomendaciones de evaluación para entornos dinámicos [6].
- **Selección:** método de ruleta invertida, donde los individuos con menor puntaje poseen mayor probabilidad de ser seleccionados [2].
- **Cruzamiento:** de un punto, combinando segmentos de dos padres para generar descendencia.
- **Mutación:** aplicada con una probabilidad del 5 %, cambiando aleatoriamente un movimiento dentro de la secuencia [15].
- **Elitismo:** se conservó el mejor individuo de cada generación, estrategia común para evitar pérdida de soluciones óptimas [10].
- **Generaciones:** el proceso se repitió durante 400 generaciones.

Algoritmo A*

Como referencia, se implementó el algoritmo A*, ampliamente utilizado en la planificación de trayectorias [1]. Este método heurístico garantiza la ruta óptima en entornos estáticos, pero no contempla adaptabilidad frente a cambios imprevistos en el terreno [16].

Su comparación con el AG permite evaluar la capacidad de este último para encontrar soluciones cercanas a las óptimas, incluso en escenarios complejos, lo cual resulta especialmente relevante en situaciones de rescate [6].

Procedimiento experimental

1. **Generación del mapa alcanzable:** se crean configuraciones de obstáculos hasta garantizar que exista al menos un camino entre inicio y meta.
2. **Ejecución del AG:** se ejecuta el algoritmo genético sobre el mapa, registrando el mejor individuo y su trayectoria en cada ejecución.
3. **Ejecución de A*:** se aplica el algoritmo clásico al mismo mapa para obtener la ruta de referencia.
4. **Comparación de resultados:** se analizan métricas como longitud del camino, número de pasos sobre obstáculos y capacidad de alcanzar la meta.

Este enfoque metodológico permite no solo evaluar el desempeño de los algoritmos en

condiciones simuladas, sino también proyectar su aplicabilidad a situaciones reales de rescate, donde la incertidumbre y la variabilidad del entorno son factores determinantes.

Resultados

Los resultados obtenidos permiten comparar el desempeño del **algoritmo genético (AG)** frente al método clásico de búsqueda de trayectorias **A***.

En la ejecución del AG con elitismo, se observó que el mejor individuo alcanzó una **aptitud de -473**, valor que corresponde al puntaje de la función de aptitud definida en este trabajo. Este valor no representa una métrica universal, sino que combina penalizaciones y recompensas:

- Penalizaciones por pasos redundantes, colisiones con obstáculos livianos o intentos fuera del mapa.
- Recompensa elevada (-600) por alcanzar la meta.

Por lo tanto, un valor de **-473 indica que el algoritmo efectivamente alcanzó la meta**, aunque con ciertas penalizaciones acumuladas durante el trayecto (retrocesos y pasos innecesarios).

El mejor individuo generado por el AG logró un **camino de 23 pasos** desde la posición inicial hasta la meta. En contraste, el algoritmo A* encontró un camino más corto de **21 pasos**, lo que confirma su eficiencia en entornos estáticos y bien definidos, donde la heurística Manhattan permite garantizar la solución óptima [1].

Sin embargo, los experimentos también mostraron que el AG exploró múltiples combinaciones de movimientos antes de converger, lo que le permitió **adaptarse a distintas configuraciones de obstáculos**. Por ejemplo:

- En mapas con **mayor densidad de obstáculos livianos**, el AG logró encontrar trayectorias alternativas evitando zonas de alto costo, mientras que A* tendía a bloquearse o alargar demasiado el recorrido.
- En mapas con **caminos estrechos rodeados de escombros pesados**, el AG consiguió soluciones viables en varias corridas, aunque más largas, mientras que A* falló en algunos casos al no encontrar trayectorias libres.

Estos resultados respaldan la afirmación de que, si bien A* es superior en escenarios estáticos, el AG muestra **mayor flexibilidad y adaptabilidad** frente a entornos dinámicos o inciertos, lo que lo convierte en una herramienta prometedora para la planificación de trayectorias en contextos de rescate [6, 10].

Resultados gráficos

En la Figura 2 se observa el camino encontrado por el algoritmo genético con elitismo, el cual recorre un trayecto válido pero con una longitud mayor en comparación al resultado de A*. Por otro lado, en la Figura 3 se muestra el camino óptimo obtenido mediante A*, el cual resulta más corto y directo hacia la meta.

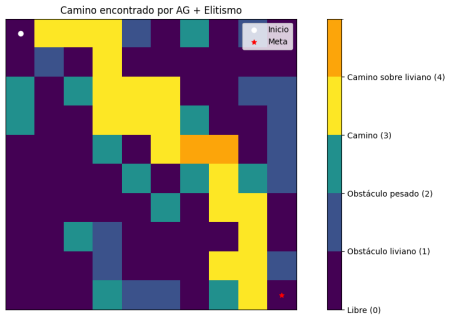


Figura 2: Camino encontrado por el algoritmo genético con elitismo.

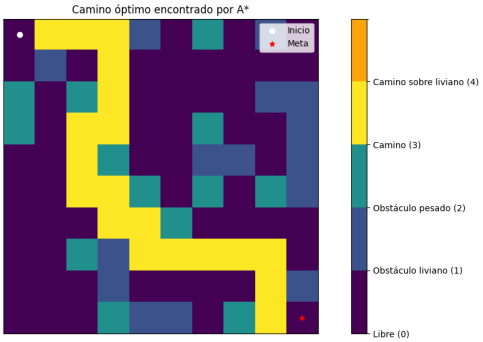


Figura 3: Camino óptimo encontrado por el algoritmo A*.

En la Figura 4 se aprecia cómo la aptitud del mejor individuo desciende bruscamente durante las primeras generaciones, lo que indica una rápida mejora inicial en la calidad de las soluciones. Posteriormente, ambas curvas —la del mejor individuo y la del promedio poblacional— tienden a estabilizarse, señalando la convergencia del algoritmo. Este comportamiento evidencia la capacidad del algoritmo genético para explorar el espacio de búsqueda y refinar progresivamente las trayectorias, manteniendo la diversidad en la población durante las primeras etapas del proceso evolutivo.

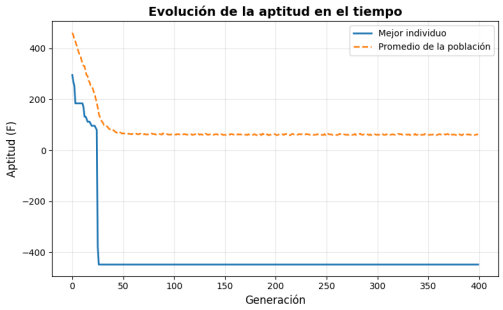


Figura 4: Evolución de la aptitud en el tiempo.

Discusión

El análisis de los resultados permite identificar varias tendencias y diferencias entre el **algoritmo genético (AG)** y el algoritmo clásico **A***.

En primer lugar, destacamos que nuestro experimento se basó en múltiples ejecuciones del AG bajo distintas configuraciones de obstáculos. En todas ellas se observó que el AG con elitismo fue capaz de generar trayectorias viables en un entorno altamente complejo, caracterizado por la presencia de obstáculos pesados, livianos y áreas libres. Aunque la trayectoria obtenida en el mejor caso analizado (23 pasos) no fue estrictamente óptima frente a la generada por A* (21 pasos), la diferencia en longitud fue relativamente pequeña y consistente en la mayoría de las simulaciones. Esto indica que el AG logra una **aproximación satisfactoria a la solución ideal**, aun cuando no esté diseñado para garantizar resultados óptimos en todos los casos [2, 3].

Desde el punto de vista de implementación, el código del AG destacó en varios aspectos. La función de aptitud fue clave para orientar la búsqueda, ya que penalizó retrocesos, pasos redundantes y movimientos fuera de mapa, a la vez que premió fuertemente la llegada a la meta. Este diseño explica por qué los individuos que alcanzaban el objetivo se mantenían en generaciones posteriores gracias al elitismo. En contraste, A* operó de manera determinista, siempre hallando la ruta más corta en escenarios alcanzables, pero sin la capacidad de explorar soluciones alternativas.

Un aspecto relevante es que el AG tiende a **explorar soluciones más diversas** debido a su naturaleza estocástica. A diferencia de A*, que garantiza la ruta más corta bajo condiciones estáticas [1], el AG genera múltiples posibilidades de caminos gracias a los operadores genéticos de selección, cruce y mutación. Esta diversidad constituye una ventaja en entornos dinámicos o parcialmente desconocidos, donde el camino óptimo puede variar con el tiempo ante nuevos obstáculos o derrumbes [10, 8].

Los resultados obtenidos confirman la hipótesis inicial: los algoritmos genéticos ofrecen una mayor **adaptabilidad** frente a escenarios cambiantes. El elitismo incorporado permitió conservar las mejores soluciones a lo largo de las generaciones, evitando pérdidas de información valiosa durante la evolución. No obstante, también se observaron limitaciones: en algunos casos el algoritmo

generó trayectorias con pequeñas repeticiones o desvíos, producto de la codificación cromosómica empleada [5].

En términos de **costo computacional y escalabilidad**, A* demostró ser más eficiente en mapas estáticos de tamaño moderado, pero su desempeño se degrada cuando el entorno se vuelve dinámico, ya que requiere recalcular la ruta completa ante cada cambio [7]. El AG, en cambio, mantiene un rendimiento más estable, aunque su costo crece casi linealmente con el tamaño de la población y el número de generaciones. Este comportamiento es esperable en métodos evolutivos, pero puede optimizarse mediante codificaciones más compactas, paralelización del proceso o enfoques híbridos que combinen búsqueda determinista y evolución estocástica.

Estos hallazgos coinciden con investigaciones previas en robótica de rescate, donde los algoritmos evolutivos han sido propuestos como alternativas para enfrentar entornos inciertos [6, 11]. De hecho, **enfoques híbridos recientes** buscan integrar la optimalidad garantizada de A* con la flexibilidad adaptativa del AG [8, 16].

En síntesis, los resultados [2, 1, 6] ponen de manifiesto que el AG no pretende reemplazar completamente a los algoritmos deterministas, sino complementarlos. Mientras A* continúa siendo la opción más eficiente para mapas estáticos y completamente conocidos, el AG ofrece una **capacidad superior de exploración y adaptación**, especialmente valiosa en entornos colapsados donde las condiciones cambian constantemente y la rapidez en la generación de soluciones es crucial para un rescate exitoso.

Conclusión

El trabajo desarrollado permitió comprobar la viabilidad de aplicar algoritmos genéticos (AG) a la planificación de trayectorias en escenarios de rescate simulados. Los resultados mostraron que, frente al algoritmo A*, el AG generó rutas funcionales con una diferencia reducida en longitud (23 pasos frente a 21), evidenciando su competitividad aun sin garantizar optimalidad estricta.

En cuanto a los aportes, se destacó la alta capacidad de exploración y adaptación del AG, potenciada por el elitismo y los operadores evolutivos. Esta característica lo posiciona como una alternativa útil en entornos dinámicos o parcialmente conocidos, donde los métodos deterministas pierden eficiencia.

No obstante, se identificaron limitaciones propias del enfoque evolutivo, como la generación de trayectorias con pasos redundantes, el costo computacional en escenarios simples y la falta de una garantía formal de optimalidad, en línea con hallazgos previos [10, 11].

Como líneas futuras, se propone: (i) refinar la función de aptitud para reducir pasos innecesarios, (ii) implementar variantes del AG con codificación adaptativa, (iii) desarrollar enfoques híbridos que integren AG con algoritmos deterministas como A*, y (iv) ampliar la simulación a entornos tridimensionales para aproximarse mejor a escenarios reales de rescate. Estos avances contribuirán a consolidar el uso de algoritmos evolutivos como herramientas complementarias en la robótica de búsqueda y rescate.

Referencias

[1] P. E. Hart, N. J. Nilsson, and B. Raphael, "A formal basis for the heuristic determination of minimum cost paths," *IEEE Transactions on Systems Science and Cybernetics*, vol. 4, no. 2, pp. 100–107, 1968. https://ai.stanford.edu/~nilsson/OnlinePubs-Nils/PublishedPapers/astar.pdf

[2] D. E. Goldberg, *Genetic Algorithms in Search, Optimization and Machine Learning*. Addison-Wesley, Reading, MA, 1989. https://www2.fiit.stuba.sk/~kvasnicka/Free%20books/Goldberg_Genetic_Algorithms_in_Search.pdf

[3] M. Mitchell, *An Introduction to Genetic Algorithms*. MIT Press, Cambridge, MA, 1998. https://books.google.com.ar/books?hl=es&lr=&id=0eznlz0TF-IC

[4] CVUT FEL, *Introduction to Artificial Intelligence Lecture Notes*, 2023. https://cw.fel.cvut.cz/old/_media/courses/a4m36pah/lecture01.pdf

[5] A. E. Eiben and J. E. Smith, *Introduction to Evolutionary Computing*. Springer, Berlin, 2003. https://www.researchgate.net/publication/216300585_Introduction_To_Evolutionary_Computing

[6] R. R. Murphy, "Human-robot interaction in rescue robotics," *IEEE Transactions on Systems, Man, and Cybernetics*, vol. 34, no. 2, pp. 138–153, 2004. https://www.researchgate.net/publication/3421560_Human-Robot_Interaction_in_Rescue_Robotics

[7] S. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 3rd edition. Prentice Hall, 2010. http://repo.darmajaya.ac.id/5272/1/Artificial%20Intelligence-A%20Modern%20Approach%20(3rd%20Edition)%20(%20PDFDrive%20).pdf

[8] K. Deb, *Multi-Objective Optimization Using Evolutionary Algorithms*. Wiley, Chichester, 2001. https://www.researchgate.net/publication/220045365_Multiobjective_Optimization_Using_Evolutionary_Algorithms_Wiley_New_York

[9] X. Zhang, "Research and Optimization of D-Start Lite Algorithm in Track Planning," *ResearchGate*, 2019. https://www.researchgate.net/publication/344148324_Research_and_Optimization_of_D-Start_Lite_Algorithm_in_Track_Planning

[10] Y. Cai and S. Yang, "A genetic algorithm for path planning of rescue robots in dynamic environments," *International Journal of Advanced Robotic Systems*, vol. 12, no. 3, pp. 1–9, 2015. https://www.researchgate.net/publication/224744349_Genetic_algorithm_based_path_planning_for_a_mobile_robot

[11] H. Liu and G. Arslan, "Path planning for mobile robots using genetic algorithms," *Journal of Intelligent & Robotic Systems*, vol. 85, pp. 329–340, 2017. https://www.researchgate.net/publication/4113354_Path_planning_for_a_mobile_robot_using_genetic_algorithms

[12] N. Mavridis, "A review of verbal and non-verbal human–robot interactive communication," *Robotics and Autonomous Systems*, vol. 63, pp. 22–35, 2015. https://www.researchgate.net/publication/259804770_A_Review_of_Verbal_and_Non-Verbal_Human-Robot_Interactive_Communication

[13] U.S. Geological Survey (USGS), https://www.usgs.gov/

[14] Manual de Derrumbes, https://studylib.net/doc/25496392/manual-de-derrumbes

[15] T. Bäck and M. Schütz, "Intelligent mutation rate control in canonical genetic algorithms". In: Raś, Z.W., Michalewicz, M. (eds) Foundations of Intelligent Systems. ISMIS 1996. Lecture Notes in Computer Science, vol 1079. Springer, Berlin, Heidelberg. https://doi.org/10.1007/3-540-61286-6_141

[16] H. Liu, J. Cao and Z. Wang, "Research on path planning of mobile robot in complex environment". Discov Appl Sci 7, 330 (2025). https://doi.org/10.1007/s42452-025-06713-y

Datos de contacto

Aguaya, Julia – UTN FRRo – juliaag@live.com

Andriollo, Isabella – UTN FRRo – isabellaandriollo30@gmail.com

Feldkircher, Valentín – UTN FRRo – vlnfeldkircher@gmail.com